

# Коммуникации в распределенной и федеративной оптимизации

Александр Безносиков  
ФПМИ МФТИ, Сколтех, Иннополис, МВЗУАИ

# Введение

# Современные проблемы обучения

- Экспоненциальный рост размеров моделей и объемов данных.




Рисунок: Динамика роста современных языковых моделей




Рисунок: Динамика роста датасетов

# Разновидности распределенного обучения

- Кластерное обучение (крупные игроки): обучаем в пределах одного большого и мощного вычислительного кластера
- Коллаборативное обучение (все игроки): объединяем вычислительные ресурсы по сети Интернет

# Разновидности распределенного обучения

- Кластерное обучение (крупные игроки): обучаем в пределах одного большого и мощного вычислительного кластера
- Коллаборативное обучение (все игроки): объединяем вычислительные ресурсы по сети Интернет
- Федеративное обучение (другая парадигма): обучаемся на локальных данных пользователей, используя их вычислительные мощности




Рисунок: Федеративное обучение

# Самая популярная распределенная постановка

- Постановка (горизонтальная, оффлайн):

$$\min_{w \in \mathbb{R}^d} f(w) := \frac{1}{M} \sum_{m=1}^M f_m(w) := \frac{1}{M} \sum_{m=1}^M \frac{1}{n_m} \sum_{i=1}^{n_m} l(g(w, x_i), y_i).$$

- $w$  – веса модели,  $g$  – модель,  $l$  – функция потерь.
- Данные разделены между  $M$  вычислительными устройствами, на каждом устройстве  $m$  своя локальная подвыборка  $\{x_i, y_i\}_{i=1}^{n_m}$  размера  $n_m$ .
- В фокусе этого доклада.

## Общаемся через сервер

- Посмотрим на примере, как обычный неопределенный GD становится централизованным.

## Algorithm Централизованный GD

**Вход:** Размер шага  $\gamma > 0$ , стартовая точка  $w_0 \in \mathbb{R}^d$ , количество итераций  $K$

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:   Отправить  $w_k$  всем рабочим                                ▷ выполняется сервером
3:   for  $i = 1, \dots, n$  параллельно do
4:     Принять  $w_k$  от мастера                                 ▷ выполняется рабочими
5:     Вычислить градиент  $\nabla f_m(w_k)$  в точке  $w_k$  ▷ выполняется рабочими
6:     Отправить  $\nabla f_m(w_k)$  мастеру                      ▷ выполняется рабочими
7:   end for
8:   Принять  $\nabla f_m(w_k)$  от всех рабочих                  ▷ выполняется сервером
9:   Вычислить  $\nabla f(w_k) = \frac{1}{M} \sum_{m=1}^M \nabla f_m(w_k)$  ▷ выполняется сервером
10:   $w_{k+1} = w_k - \gamma \nabla f(w_k)$                          ▷ выполняется сервером
11: end for
Выход:  $w^K$ 

```

# С чем и за что боремся?

- **Вопрос:** распределенность нужна для параллелизации, но почему не получается достигнуть полного распараллеливания?

# С чем и за что боремся?

- **Вопрос:** распределенность нужна для параллелизации, но почему не получается достигнуть полного распараллеливания?
- Коммуникационные затраты являются бесполезной тратой времени.
- Проблема коммуникационного узкого места актуальна для всех постановок распределенного обучения.
- Существует много способов борьбы за эффективные коммуникации.

## Сжатие: несмещенные и смещенные операторы

# Несмешённая компрессия (квантизация)

## Несмешённая компрессия (квантизация)

Будем называть стохастический оператор  $\mathcal{Q}(x)$  оператором несмешённой компрессии (квантизации), если для любого  $x \in \mathbb{R}^d$  выполняется:

$$\mathbb{E}[\mathcal{Q}(x)] = x, \quad \mathbb{E}[\|\mathcal{Q}(x)\|_2^2] \leq \omega \|x\|_2^2,$$

где  $\omega \geq 1$ .

# Несмешённая компрессия: примеры

## Случайная спарсификация (выбор случайных компонент)

Рассмотрим стохастический оператор

$$\text{Randk}(x) = \frac{d}{k} \sum_{i \in S} [x]_i e_i,$$

где  $k$  — некоторое фиксированное число из множества  $\{1, \dots, d\}$  (количество компонент вектора  $x$ , которые мы передаём; например, можно выбрать  $k = 1$ ),  $S$  — случайное подмножество множества  $\{1, \dots, d\}$  размера  $k$  (подмножество  $S$  выбирается случайно и равновероятно среди всех возможных подмножеств размера  $d$ ),  $[ \cdot ]_i$  —  $i$ -я компонента вектора,  $(e_1, \dots, e_d)$  — стандартный базис в  $\mathbb{R}^d$ .



Richtárik P. and Takáč M. Parallel coordinate descent methods for big data optimization

# Несмешённая компрессия: примеры

## Случайная спарсификация (выбор случайных компонент)

Рассмотрим стохастический оператор

$$\text{Randk}(x) = \frac{d}{k} \sum_{i \in S} [x]_i e_i,$$

где  $k$  — некоторое фиксированное число из множества  $\{1, \dots, d\}$  (количество компонент вектора  $x$ , которые мы передаём; например, можно выбрать  $k = 1$ ),  $S$  — случайное подмножество множества  $\{1, \dots, d\}$  размера  $k$  (подмножество  $S$  выбирается случайно и равновероятно среди всех возможных подмножеств размера  $d$ ),  $[ \cdot ]_i$  —  $i$ -я компонента вектора,  $(e_1, \dots, e_d)$  — стандартный базис в  $\mathbb{R}^d$ .



Richtárik P. and Takáč M. Parallel coordinate descent methods for big data optimization

- Вопрос: зачем нужен множитель  $\frac{d}{k}$ ?

# Несмешённая компрессия: примеры

## Случайная спарсификация (выбор случайных компонент)

Рассмотрим стохастический оператор

$$\text{Randk}(x) = \frac{d}{k} \sum_{i \in S} [x]_i e_i,$$

где  $k$  — некоторое фиксированное число из множества  $\{1, \dots, d\}$  (количество компонент вектора  $x$ , которые мы передаём; например, можно выбрать  $k = 1$ ),  $S$  — случайное подмножество множества  $\{1, \dots, d\}$  размера  $k$  (подмножество  $S$  выбирается случайно и равновероятно среди всех возможных подмножеств размера  $d$ ),  $[ \cdot ]_i$  —  $i$ -я компонента вектора,  $(e_1, \dots, e_d)$  — стандартный базис в  $\mathbb{R}^d$ .



Richtárik P. and Takáč M. Parallel coordinate descent methods for big data optimization

- **Вопрос:** зачем нужен множитель  $\frac{d}{k}$ ? Для несмещённости.

# Несмешённая компрессия: примеры

- Вопрос: Чему равно  $\omega$  для случайной спарсификации?

## Несмешённая компрессия: примеры

- **Вопрос:** Чему равно  $\omega$  для случайной спарсификации?  $\frac{d}{k}$ .  
Каждая координата попадет в  $\mathcal{Q}(x)$  с вероятностью  $\frac{k}{d}$ , поэтому

$$\begin{aligned}\mathbb{E} [\|\mathcal{Q}(x)\|^2] &= \mathbb{E} \left[ \sum_{i=1}^d [\mathcal{Q}(x)]_i^2 \right] \\ &= \frac{d^2}{k^2} \left[ \sum_{i=1}^d \frac{k}{d} [x]_i^2 \right] \\ &= \frac{d}{k} \|x\|^2.\end{aligned}$$

Здесь  $[\cdot]_i$  –  $i$ ая координата вектора.

# Несмешённая компрессия: примеры

## Трёхуровневая $\ell_2$ -квантизация

Рассмотрим следующий оператор:

$[\mathcal{Q}(x)]_i = \|x\|_2 \text{sign}(x_i) \xi_i$ ,  $i = 1, \dots, d$ , где  $[\cdot]_i$  —  $i$ -я компонента вектора, и  $\xi_i$  — случайная величина, имеющая распределение Бернулли с параметром  $\frac{|x_i|}{\|x\|_2}$ , т. е.

$$\xi_i = \begin{cases} 1 & \text{с вероятностью } \frac{|x_i|}{\|x\|_2}, \\ 0 & \text{с вероятностью } 1 - \frac{|x_i|}{\|x\|_2}. \end{cases}$$

Таким образом, если мы хотим передать вектор  $\mathcal{Q}(x)$ , то нам нужно передать вектор, состоящий из нулей и  $\pm 1$ , и вещественное число  $\|x\|_2$ , причём вероятность обнуления компоненты тем больше, чем компонента меньше по модулю. Можно показать, что данный оператор является несмешённой компрессией с константой  $\omega = \sqrt{d}$ .



Alistarh D. et al. QSGD: Communication-Efficient SGD via Gradient Quantization and Encoding



# Несмешённая компрессия: примеры

- **Вопрос:** Будет ли округление несмешенным оператором?
- **Вопрос:** Какое округление кажется наиболее естественным для вычислений на компьютере?



# Несмешённая компрессия: примеры

Натуральная компрессия (случайное округление к степени двойки)

Рассмотрим следующий оператор:

$$[\mathcal{Q}(x)]_i = \begin{cases} \lfloor [x]_i \rfloor_2, & \text{с вероятностью } p = \frac{[x]_i - \lfloor [x]_i \rfloor_2}{\lceil [x]_i \rceil_2 - \lfloor [x]_i \rfloor_2}, \\ \lceil [x]_i \rceil_2, & \text{с вероятностью } 1 - p \end{cases},$$

где  $[ \cdot ]_i$  –  $i$ -я компонента вектора,  $\lfloor \cdot \rfloor_2$  – ближайшая степень двойки снизу,  $\lceil \cdot \rceil_2$  – ближайшая степень двойки сверху. Округляем в двум ближайшим степеням двойки, вероятность округления больше, чем реальное число ближе к соответствующей степени двойки. Можно показать, что  $\omega = \frac{9}{8}$ .



Horváth S. et al. Natural compression for distributed deep learning



# Несмешенная компрессия: идея

- Самая простая идея, которая приходит в голову, состоит в том, чтобы использовать параллельный GD, но к градиентам, пересылаемым от рабочих на сервер, применять несмешённую компрессию.

# Квантизированный GD (QGD)

## Algorithm QGD

**Вход:** размер шага  $\gamma > 0$ , стартовая точка  $w_0 \in \mathbb{R}^d$ , количество итераций  $K$

- 1: **for**  $k = 0, 1, \dots, K - 1$  **do**
  - 2:     Отправить  $w_k$  всем рабочим ▷ выполняется сервером
  - 3:     **for**  $m = 1, \dots, M$  параллельно **do**
  - 4:         Принять  $w_k$  от мастера ▷ выполняется рабочими
  - 5:         Вычислить градиент  $\nabla f_m(w_k)$  в точке  $w_k$  ▷ выполняется рабочими
  - 6:         Независимо сгенерировать  $g_{k,m} = \mathcal{Q}(\nabla f_m(w_k))$  ▷ выполняется рабочими
  - 7:         Отправить  $g_{k,m}$  мастеру ▷ выполняется рабочими
  - 8:     **end for**
  - 9:     Принять  $g_{k,m}$  от всех рабочих ▷ выполняется сервером
  - 10:    Вычислить  $g_k = \frac{1}{M} \sum_{m=1}^M g_{k,m}$  ▷ выполняется сервером
  - 11:     $w_{k+1} = w_k - \gamma g_k$  ▷ выполняется сервером
  - 12: **end for**
- Выход:**  $w^K$

## Несмешенная компрессия: доказательство

- Будем доказывать в случае, когда все  $f_m$  являются  $L$ -гладкими и  $\mu$ -сильно выпуклыми.
- Рассмотрим одну итерацию метода:

$$\|w_{k+1} - w^*\|^2 = \|w_k - w^*\|^2 - 2\gamma \langle g_k, w_k - w^* \rangle + \|g_k\|^2.$$

## Несмешенная компрессия: доказательство

- Будем доказывать в случае, когда все  $f_m$  являются  $L$ -гладкими и  $\mu$ -сильно выпуклыми.
- Рассмотрим одну итерацию метода:

$$\|w_{k+1} - w^*\|^2 = \|w_k - w^*\|^2 - 2\gamma \langle g_k, w_k - w^* \rangle + \|g_k\|^2.$$

- Берем условное мат.ожидание по случайноти только на итерации  $k$ :

$$\begin{aligned}\mathbb{E} [\|w_{k+1} - w^*\|^2 | w_k] &= \|w_k - w^*\|^2 - 2\gamma \langle \mathbb{E}[g_k | w_k], w_k - w^* \rangle \\ &\quad + \gamma^2 \mathbb{E} [\|g_k\|^2 | w_k].\end{aligned}$$

## Несмешенная компрессия: доказательство

- Работаем с  $\mathbb{E}[g_k \mid w_k]$ :

$$\begin{aligned}\mathbb{E}[g_k \mid w_k] &= \frac{1}{M} \sum_{m=1}^M \mathbb{E}[g_{k,m} \mid w_k] \\ &= \frac{1}{M} \sum_{m=1}^M \mathbb{E}[\mathbb{E}[\mathcal{Q}(\nabla f_m(w_k)) \mid \nabla f_m(w_k)] \mid w_k] \\ &= \frac{1}{M} \sum_{m=1}^M \mathbb{E}[\nabla f_m(w_k) \mid w_k] = \frac{1}{M} \sum_{m=1}^M \nabla f_m(w_k) = \nabla f(w_k).\end{aligned}$$

## Несмешенная компрессия: доказательство

- Работаем с  $\mathbb{E}[g_k \mid w_k]$ :

$$\begin{aligned}\mathbb{E}[g_k \mid w_k] &= \frac{1}{M} \sum_{m=1}^M \mathbb{E}[g_{k,m} \mid w_k] \\ &= \frac{1}{M} \sum_{m=1}^M \mathbb{E}[\mathbb{E}[\mathcal{Q}(\nabla f_m(w_k)) \mid \nabla f_m(w_k)] \mid w_k] \\ &= \frac{1}{M} \sum_{m=1}^M \mathbb{E}[\nabla f_m(w_k) \mid w_k] = \frac{1}{M} \sum_{m=1}^M \nabla f_m(w_k) = \nabla f(w_k).\end{aligned}$$

- Работаем с  $\mathbb{E}[\|g_k\|^2 \mid w_k]$ :

$$\mathbb{E}[\|g_k\|^2 \mid w_k] = \mathbb{E}\left[\left\|\frac{1}{M} \sum_{m=1}^M g_{k,m}\right\|^2 \mid x_k\right] = \frac{1}{M^2} \mathbb{E}\left[\left\|\sum_{m=1}^M g_{k,m}\right\|^2 \mid w^k\right]$$

## Несмешенная компрессия: доказательство

- Продолжаем и применяем первое свойство (несмешенность) в определении компрессии:

$$\begin{aligned}\mathbb{E} [\|g_k\|^2 \mid w_k] &= \frac{1}{M^2} \mathbb{E} \left[ \left\| \sum_{m=1}^M g_{k,m} \right\|^2 \mid w_k \right] \\ &= \frac{1}{M^2} \sum_{m=1}^M \mathbb{E} [\|g_{k,m}\|^2 \mid w_k] \\ &\quad + \frac{2}{M^2} \sum_{m \neq l} \mathbb{E} [\langle g_{k,m}, g_{k,l} \rangle \mid w_k] \\ &= \frac{1}{M^2} \sum_{m=1}^M \mathbb{E} [\|g_{k,m}\|^2 \mid w_k] \\ &\quad + \frac{1}{M^2} \sum_{m \neq l} \mathbb{E} [\langle \mathbb{E} [g_{k,m} \mid \nabla f_m(w_k)], \mathbb{E} [g_{k,l} \mid \nabla f_l(x_k)] \rangle \mid w_k].\end{aligned}$$

# Несмешенная компрессия: доказательство

- Продолжаем и применяем первое свойство (несмешенность) в определении компрессии:

$$\begin{aligned}\mathbb{E} [\|g_k\|^2 \mid w_k] &= \frac{1}{M^2} \mathbb{E} \left[ \left\| \sum_{m=1}^M g_{k,m} \right\|^2 \mid w_k \right] \\ &= \frac{1}{M^2} \sum_{m=1}^M \mathbb{E} [\|g_{k,m}\|^2 \mid w_k] \\ &\quad + \frac{2}{M^2} \sum_{m \neq l} \mathbb{E} [\langle g_{k,m}, g_{k,l} \rangle \mid w_k] \\ &= \frac{1}{M^2} \sum_{m=1}^M \mathbb{E} [\|g_{k,m}\|^2 \mid w_k] \\ &\quad + \frac{1}{M^2} \sum_{m \neq l} \mathbb{E} [\langle \mathbb{E} [g_{k,m} \mid \nabla f_m(w_k)], \mathbb{E} [g_{k,l} \mid \nabla f_l(x_k)] \rangle \mid w_k].\end{aligned}$$

## Несмешенная компрессия: доказательство

- Продолжаем и применяем второе свойство в определении компрессии:

$$\begin{aligned}\mathbb{E} [\|g_k\|^2 \mid w_k] &= \frac{1}{M^2} \sum_{m=1}^M \mathbb{E} [\|\mathcal{Q}(\nabla f_m(w_k))\|^2 \mid w_k] \\ &\quad + \frac{1}{M^2} \sum_{m \neq l} \langle \nabla f_m(w_k), \nabla f_l(w_k) \rangle \\ &\leq \frac{\omega}{M^2} \sum_{m=1}^M \|\nabla f_m(w_k)\|^2 \\ &\quad + \|\nabla f(w_k)\|^2 \\ &\leq \frac{2\omega}{M^2} \sum_{m=1}^M \|\nabla f_m(w_k) - \nabla f_m(w^*)\|^2 \\ &\quad + \frac{2\omega}{M^2} \sum_{m=1}^M \|\nabla f_m(w^*)\|^2 + \|\nabla f(w_k) - \nabla f(w^*)\|^2.\end{aligned}$$

## Несмешенная компрессия: доказательство

- Продолжаем и применяем второе свойство в определении компрессии:

$$\begin{aligned}\mathbb{E} [\|g_k\|^2 \mid w_k] &\leq \frac{4\omega L}{M^2} \sum_{m=1}^M (f_m(w_k) - f_m(w^*) - \langle \nabla f_m(w^*), w_k - w^* \rangle) \\ &\quad + \frac{2\omega}{M^2} \sum_{m=1}^M \|\nabla f_m(x^*)\|^2 + 2L(f(x_k) - f(x^*)) \\ &= \frac{4\omega L}{M} (f(x_k) - f(x^*)) \\ &\quad + \frac{2\omega}{M^2} \sum_{m=1}^M \|\nabla f_m(x^*)\|^2 + 2L(f(x_k) - f(x^*)).\end{aligned}$$

# Несмешенная компрессия: доказательство

- Все, что получили:

$$\begin{aligned}\mathbb{E} [\|w_{k+1} - w^*\|^2 \mid w_k] = & \|w_k - w^*\|^2 - 2\gamma \langle \mathbb{E}[g_k \mid w_k], w_k - w^* \rangle \\ & + \gamma^2 \mathbb{E} [\|g_k\|^2 \mid w_k].\end{aligned}$$

$$\mathbb{E}[g_k \mid w_k] = \nabla f(w_k).$$

$$\begin{aligned}\mathbb{E} [\|g_k\|^2 \mid w_k] \leq & \frac{4\omega L}{M} (f(w_k) - f(w^*)) \\ & + \frac{2\omega}{M^2} \sum_{m=1}^M \|\nabla f_m(w^*)\|^2 + 2L(f(w_k) - f(w^*)).\end{aligned}$$

# Несмешенная компрессия: доказательство

- Объединяем:

$$\begin{aligned}\mathbb{E} [\|w_{k+1} - w^*\|^2 \mid w_k] &\leq \|w_k - w^*\|^2 - 2\gamma \langle \nabla f(w_k), w_k - w^* \rangle \\&\quad + 2\gamma^2 L \left( \frac{2\omega}{M} + 1 \right) (f(w_k) - f(w^*)) \\&\quad + \frac{2\gamma^2 \omega}{M^2} \sum_{m=1}^M \|\nabla f_m(w^*)\|^2.\end{aligned}$$

- Пользуемся сильной выпуклостью:

$$\begin{aligned}\mathbb{E} [\|w_{k+1} - w^*\|^2 \mid w_k] &\leq \|w_k - w^*\|^2 \\&\quad - 2\gamma \left( \frac{\mu}{2} \|w_k - w^*\|^2 + f(w_k) - f(w^*) \right) \\&\quad + 2\gamma^2 L \left( \frac{2\omega}{M} + 1 \right) (f(w_k) - f(w^*)) \\&\quad + \frac{2\gamma^2 \omega}{M^2} \sum_{m=1}^M \|\nabla f_m(w^*)\|^2.\end{aligned}$$

## Несмешенная компрессия: доказательство

- Если взять полное математическое ожидание

$$\begin{aligned}\mathbb{E} [\|x_{k+1} - x^*\|^2] &\leq (1 - \gamma\mu)\mathbb{E} [\|x_k - x^*\|^2] \\ &\quad - 2\gamma \left[ 1 - \gamma L \left( \frac{2\omega}{M} + 1 \right) \right] \mathbb{E} [(f(x_k) - f(x^*))] \\ &\quad + \frac{2\gamma^2\omega}{M^2} \sum_{m=1}^M \|\nabla f_m(x^*)\|^2.\end{aligned}$$

- Если  $\gamma \leq L^{-1} \left( \frac{2\omega}{M} + 1 \right)^{-1}$ , то

$$\begin{aligned}\mathbb{E} [\|x_{k+1} - x^*\|^2] &\leq (1 - \gamma\mu)\mathbb{E} [\|x_k - x^*\|^2] \\ &\quad + \frac{2\gamma^2\omega}{M^2} \sum_{m=1}^M \|\nabla f_m(x^*)\|^2.\end{aligned}$$

## Теорема (QGD)

Пусть все локальные функции  $f_m$  являются  $\mu$ -сильно выпуклыми и имеют  $L$ -Липшицев градиент, тогда если  $\eta \leq L^{-1} \left(\frac{2\omega}{M} + 1\right)^{-1}$ , то

$$\mathbb{E} [\|x_K - x^*\|^2] = \mathcal{O} \left( (1 - \gamma\mu)^K \|x_0 - x^*\|^2 + \frac{1}{K} \cdot \frac{2\omega}{\mu M^2} \sum_{m=1}^M \|\nabla f_m(x^*)\|^2 \right).$$

При получении данного результата так же использовался подбор  $\gamma$  из работы:



Stich S. Unified Optimal Analysis of the (Stochastic) Gradient Method

## Теорема (QGD)

Пусть все локальные функции  $f_m$  являются  $\mu$ -сильно выпуклыми и имеют  $L$ -Липшицев градиент, тогда если  $\eta \leq L^{-1} \left(\frac{2\omega}{M} + 1\right)^{-1}$ , то

$$\mathbb{E} [\|x_K - x^*\|^2] = \mathcal{O} \left( (1 - \gamma\mu)^K \|x_0 - x^*\|^2 + \frac{1}{K} \cdot \frac{2\omega}{\mu M^2} \sum_{m=1}^M \|\nabla f_m(x^*)\|^2 \right)$$

При получении данного результата так же использовался подбор  $\gamma$  из работы:



Stich S. Unified Optimal Analysis of the (Stochastic) Gradient Method

- **Вопрос:** какие проблемы есть в этой оценке? (вспомните оценку сходимости GD)

## Теорема (QGD)

Пусть все локальные функции  $f_m$  являются  $\mu$ -сильно выпуклыми и имеют  $L$ -Липшицев градиент, тогда если  $\eta \leq L^{-1} \left(\frac{2\omega}{M} + 1\right)^{-1}$ , то

$$\mathbb{E} [\|x_K - x^*\|^2] = \mathcal{O} \left( (1 - \gamma\mu)^K \|x_0 - x^*\|^2 + \frac{1}{K} \cdot \frac{2\omega}{\mu M^2} \sum_{m=1}^M \|\nabla f_m(x^*)\|^2 \right).$$

При получении данного результата так же использовался подбор  $\gamma$  из работы:



Stich S. Unified Optimal Analysis of the (Stochastic) Gradient Method

- **Вопрос:** какие проблемы есть в этой оценке? (вспомните оценку сходимости GD) Сублинейная сходимость (зависит от гетерогенности данных).

# QGD: сходимость

- Поведение на практике:




Рисунок: Поведение методов с несмещенным оператором сжатия и постоянным шагом

- В теории шаг подбирался хитро, при постоянном шаге теория предугадывает ровно этот же эффект – ранний выход на плато.

- Метод DIANA – QGD с памятью:

## Algorithm DIANA (скетч)

1: Каждое устройство  $m$  обладает вектором "памяти"  $h_0^m = 0$

2: Сервер хранит  $h_0 = \frac{1}{M} \sum_{m=1}^M h_0^m = 0$

3: Досылаем на сервер сжатую версию разницы  $\mathcal{Q}(\nabla f_m(w^k) - h_k^m)$

4: Обновляем память  $h_{k+1}^m = h_k^m + \alpha \mathcal{Q}(\nabla f_m(w^k) - h_k^m)$

5: Сервер вычисляет  $g_k = h_k + \frac{1}{M} \sum_{m=1}^M \mathcal{Q}(\nabla f_m(w^k) - h_k^m)$

6: Для апдейта  $w_{k+1} = w_k - \gamma g_k$

7: Сервер обновляет  $h_{k+1} = h_k + \alpha \frac{1}{M} \sum_{m=1}^M \mathcal{Q}(\nabla f_m(w^k) - h_k^m)$



## QGD и DIANA: сходимость

- **Вопрос:** Какие есть еще вопросы к сходимости/оценкам сходимости?

- **Вопрос:** Какие есть еще вопросы к сходимости/оценкам сходимости? Лучше ли вообще сходится?
- Лучшая оценка на число коммуникаций для неускоренного метода с несмещенной компрессией (DIANA):

$$\mathcal{O}\left(\left[1 + \frac{\omega}{M}\right] \frac{L}{\mu} \log \frac{1}{\varepsilon}\right).$$

- Оценка на число коммуникаций для GD:

$$\mathcal{O}\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right).$$

- С точки зрения **числа коммуникаций** методы с компрессией уступают базовым методам – это ожидаемо (плата за сжатие).  
НО!

## QGD и DIANA: сходимость

- Компрессоры сжимают информацию в  $\beta$  раз и типично, что  $\beta \geq \omega$ .

## QGD и DIANA: сходимость

- Компрессоры сжимают информацию в  $\beta$  раз и типично, что  $\beta \geq \omega$ .
- Лучшая оценка на число информации для неускоренного метода с несмещенной компрессией (DIANA):

$$\mathcal{O} \left( \left[ \frac{1}{\beta} + \frac{1}{M} \right] \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Оценка на число информации для GD:

$$\mathcal{O} \left( \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

## QGD и DIANA: сходимость

- Компрессоры сжимают информацию в  $\beta$  раз и типично, что  $\beta \geq \omega$ .
- Лучшая оценка на число информации для неускоренного метода с несмешенной компрессией (DIANA):

$$\mathcal{O} \left( \left[ \frac{1}{\beta} + \frac{1}{M} \right] \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Оценка на число информации для GD:

$$\mathcal{O} \left( \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Несмешенный компрессор доказуемо улучшает число передаваемой информации, фактор улучшения:  $\left[ \frac{1}{\beta} + \frac{1}{M} \right]$ .

## QGD и DIANA: сходимость

- Компрессоры сжимают информацию в  $\beta$  раз и типично, что  $\beta \geq \omega$ .
- Лучшая оценка на число информации для неускоренного метода с несмешенной компрессией (DIANA):

$$\mathcal{O} \left( \left[ \frac{1}{\beta} + \frac{1}{M} \right] \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Оценка на число информации для GD:

$$\mathcal{O} \left( \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Несмешенный компрессор доказуемо улучшает число передаваемой информации, фактор улучшения:  $\left[ \frac{1}{\beta} + \frac{1}{M} \right]$ .
- Смешенный компрессор не улучшает число передаваемой информации в общем случае.

# Сервера может и не быть

- Часто на практике "централизованные коммуникации через сервер" реализованы без "сервера".
- Архитектура с AllGather/AllReduce процедурой: задан некоторый граф связей/коммуникаций, обмен сообщениями происходит согласно этому графу, в том числе можно организовать усреднение.



Chan, E. et al. Collective communication: theory, practice, and experience

# Централизованные коммуникации без сервера

Operation	Before				After			
Broadcast	Node 0 $x$	Node 1	Node 2	Node 3	Node 0 $x$	Node 1 $x$	Node 2 $x$	Node 3 $x$
Reduce(-to-one)	Node 0 $x^{(0)}$	Node 1 $x^{(1)}$	Node 2 $x^{(2)}$	Node 3 $x^{(3)}$	Node 0 $\sum_j x^{(j)}$	Node 1	Node 2	Node 3
Scatter	Node 0 $x_0$	Node 1	Node 2	Node 3	Node 0 $x_0$	Node 1 $x_1$	Node 2 $x_2$	Node 3 $x_3$
Gather	Node 0 $x_0$	Node 1 $x_1$	Node 2 $x_2$	Node 3 $x_3$	Node 0 $x_0$	Node 1 $x_1$	Node 2 $x_2$	Node 3 $x_3$
Allgather	Node 0 $x_0$	Node 1 $x_1$	Node 2 $x_2$	Node 3 $x_3$	Node 0 $x_0$	Node 1 $x_1$	Node 2 $x_2$	Node 3 $x_3$
Reduce-scatter	Node 0 $x_0^{(0)}$	Node 1 $x_1^{(0)}$	Node 2 $x_2^{(0)}$	Node 3 $x_3^{(0)}$	Node 0 $\sum_j x_0^{(j)}$	Node 1 $\sum_j x_1^{(j)}$	Node 2 $\sum_j x_2^{(j)}$	Node 3 $\sum_j x_3^{(j)}$
Allreduce	Node 0 $x^{(0)}$	Node 1 $x^{(1)}$	Node 2 $x^{(2)}$	Node 3 $x^{(3)}$	Node 0 $\sum_j x^{(j)}$	Node 1 $\sum_j x^{(j)}$	Node 2 $\sum_j x^{(j)}$	Node 3 $\sum_j x^{(j)}$

Рисунок: Виды коллективных централизованных коммуникаций без сервера

# Ring AllReduce




Рисунок: Картинка отсюда

# Ring AllReduce: первый шаг суммирования




Рисунок: Картинка отсюда

# Ring AllReduce: второй шаг суммирования




Рисунок: Картинка отсюда

# Ring AllReduce: первый шаг распространения




Рисунок: Картинка отсюда

# Ring AllReduce: итог




Рисунок: Картинка отсюда

# Квантизированный GD (QGD) с AllReduce

## Algorithm QGD

**Вход:** размер шага  $\gamma > 0$ , стартовая точка  $w_0 \in \mathbb{R}^d$ , количество итераций  $K$

- 1: **for**  $k = 0, 1, \dots, K - 1$  **do**
- 2:     **for**  $m = 1, \dots, M$  параллельно **do**
- 3:         Вычислить градиент  $\nabla f_m(w_k)$  в точке  $w_k$
- 4:         Независимо сгенерировать  $g_{k,m} = \mathcal{Q}(\nabla f_m(w_k))$
- 5:         Запустить AllReduce  $\{g_{k,m}\}$  и получить  $g_k = \frac{1}{M} \sum_{m=1}^M g_{k,m}$
- 6:          $w_{k+1} = w_k - \gamma g_k$
- 7:     **end for**
- 8: **end for**

**Выход:**  $w^K$

# Квантизированный GD (QGD) с AllReduce

## Algorithm QGD

**Вход:** размер шага  $\gamma > 0$ , стартовая точка  $w_0 \in \mathbb{R}^d$ , количество итераций  $K$

```
1: for  $k = 0, 1, \dots, K - 1$  do
2:   for  $m = 1, \dots, M$  параллельно do
3:     Вычислить градиент  $\nabla f_m(w_k)$  в точке  $w_k$ 
4:     Независимо сгенерировать  $g_{k,m} = \mathcal{Q}(\nabla f_m(w_k))$ 
5:     Запустить AllReduce  $\{g_{k,m}\}$  и получить  $g_k = \frac{1}{M} \sum_{m=1}^M g_{k,m}$ 
6:      $w_{k+1} = w_k - \gamma g_k$ 
7:   end for
8: end for
```

**Выход:**  $w^K$

- **Вопрос:** Какие проблемы могут появиться у (например) Randk?

# Квантизированный GD (QGD) с AllReduce

## Algorithm QGD

**Вход:** размер шага  $\gamma > 0$ , стартовая точка  $w_0 \in \mathbb{R}^d$ , количество итераций  $K$

- 1: **for**  $k = 0, 1, \dots, K - 1$  **do**
- 2:     **for**  $m = 1, \dots, M$  параллельно **do**
- 3:         Вычислить градиент  $\nabla f_m(w_k)$  в точке  $w_k$
- 4:         Независимо сгенерировать  $g_{k,m} = \mathcal{Q}(\nabla f_m(w_k))$
- 5:         Запустить AllReduce  $\{g_{k,m}\}$  и получить  $g_k = \frac{1}{M} \sum_{m=1}^M g_{k,m}$
- 6:          $w_{k+1} = w_k - \gamma g_k$
- 7:     **end for**
- 8: **end for**

**Выход:**  $w^K$

- **Вопрос:** Какие проблемы могут появиться у (например) Randk?  
Однаковые ненулевые координаты у разных устройств могут вызывать коллизии.

# PermK: делаем зависимую рандомизацию

## Перестановочный компрессор (зависимый RandK)

Предположим, что  $d \geq n$  и  $d = qn$ , где  $q \geq 1$  – целое число. Пусть  $\pi = (\pi_1, \dots, \pi_d)$  – случайная перестановка  $\{1, \dots, d\}$ . Тогда для каждого  $i \in \{1, 2, \dots, n\}$  имеем следующий оператор сжатия

$$Q_i(u) = n \cdot \sum_{j=q(i-1)+1}^{qi} u_{\pi_j} e_{\pi_j}.$$



Szlendak, R. et al. Permutation Compressors for Provably Faster Distributed Nonconvex Optimization

# PermK: делаем зависимую рандомизацию

## Перестановочный компрессор (зависимый RandK)

Предположим, что  $d \geq n$  и  $d = qn$ , где  $q \geq 1$  – целое число. Пусть  $\pi = (\pi_1, \dots, \pi_d)$  – случайная перестановка  $\{1, \dots, d\}$ . Тогда для каждого  $i \in \{1, 2, \dots, n\}$  имеем следующий оператор сжатия

$$Q_i(u) = n \cdot \sum_{j=q(i-1)+1}^{qi} u_{\pi_j} e_{\pi_j}.$$



Szlendak, R. et al. Permutation Compressors for Provably Faster Distributed Nonconvex Optimization

- Дружественна к централизованным коммуникациям без сервера.
- В гомогенном случае имеют физику дешевой пересылки полного градиента.

# Смещённая компрессия

- Случайный выбор – это хорошо, но и тут есть потенциал для улучшения.

## Смешённая компрессия

Будем называть (стохастический) оператор ( $x$ ) оператором смешённой компрессии, если для любого  $x \in \mathbb{R}^d$  выполняется:

$$\mathbb{E}[\|C(x) - x\|_2^2] \leq \left(1 - \frac{1}{\delta}\right) \|x\|_2^2,$$

где  $\delta \geq 0$ .

## Смещенная компрессия: примеры

"Жадная" спарсификация (выбор наибольших по модулю компонент)

Рассмотрим стохастический оператор

$$\text{Top}_k(x) = \sum_{i=d-k+1}^d x_{(i)} e_{(i)},$$

где  $k$  — некоторое фиксированное число из множества  $\{1, \dots, d\}$  (количество компонент вектора  $x$ , которые мы передаём; например, можно выбрать  $k = 1$ ), при этом координаты отсортированы по модулю:  $|x_{(1)}| \leq |x_{(2)}| \leq \dots \leq |x_{(d)}|$ ,  $(e_1, \dots, e_d)$  — стандартный базис в  $\mathbb{R}^d$ . Можно показать, что данный оператор является смещённой компрессией с константой  $\delta = \frac{d}{k}$ .



Alistarh D. et al. The convergence of sparsified gradient methods

# Смещенная компрессия: примеры

- Различные примеры компрессоров (спарсификаторы, округления и тд):



Beznosikov A. et al. On Biased Compression for Distributed Learning

- Практичный смещенный компрессор на основе итеративного SVD разложения:



Vogels T. et al. PowerSGD: Practical Low-Rank Gradient Compression for Distributed Optimization

# Смещенная компрессия: идея и доказательство в случае 1 ноды

- Использовать тот же подход, что и в несмещенном случае (QGD).

# Смещенная компрессия: идея и доказательство в случае 1 ноды

- Использовать тот же подход, что и в несмещенном случае (QGD).
- Докажем в случае одной ноды:

$$x_{k+1} = x_k - \gamma C(\nabla f(x_k)).$$

Пусть  $f$  имеет  $L$ -Липшицев градиент и является  $\mu$ -сильно выпуклой.

# Смещенная компрессия: идея и доказательство в случае 1 ноды

- Использовать тот же подход, что и в несмещенном случае (QGD).
- Докажем в случае одной ноды:

$$x_{k+1} = x_k - \gamma C(\nabla f(x_k)).$$

Пусть  $f$  имеет  $L$ -Липшицев градиент и является  $\mu$ -сильно выпуклой.

- Начнем с того, что воспользуемся Липшицевостью градиента:

$$\begin{aligned} f(w_{k+1}) &= f(w_k - \gamma C(\nabla f(w_k))) \\ &\leq f(w_k) + \langle \nabla f(w_k), -\gamma C(\nabla f(w_k)) \rangle + \frac{L}{2} \| -\gamma C(\nabla f(w_k)) \|^2 \\ &= f(w_k) - \gamma \langle C(\nabla f(w_k)), \nabla f(w_k) \rangle + \frac{\gamma^2 L}{2} \| C(\nabla f(w_k)) \|^2. \end{aligned}$$

- Определение компрессора:

$$\begin{aligned} & \|\nabla f(w_k)\|^2 - 2\mathbb{E}_C [\langle C(\nabla f(w_k)), \nabla f(w_k) \rangle] + \mathbb{E}_C [\|C(\nabla f(w_k))\|^2] \\ &= \mathbb{E}_C [\|C(\nabla f(w_k)) - \nabla f(w_k)\|^2] \leq \left(1 - \frac{1}{\delta}\right) \|\nabla f(w_k)\|^2. \end{aligned}$$

## Смещенная компрессия: доказательство в случае 1 ноды

- Определение компрессора:

$$\begin{aligned} & \|\nabla f(w_k)\|^2 - 2\mathbb{E}_C [\langle C(\nabla f(w_k)), \nabla f(w_k) \rangle] + \mathbb{E}_C [\|C(\nabla f(w_k))\|^2] \\ &= \mathbb{E}_C [\|C(\nabla f(w_k)) - \nabla f(w_k)\|^2] \leq \left(1 - \frac{1}{\delta}\right) \|\nabla f(w_k)\|^2. \end{aligned}$$

- Откуда:

$$-\gamma \mathbb{E}_C [\langle C(\nabla f(w_k)), \nabla f(w_k) \rangle] + \frac{\gamma}{2} \mathbb{E}_C [\|C(\nabla f(w_k))\|^2] \leq -\frac{\gamma}{2\delta} \|\nabla f(w_k)\|^2.$$

## Смещенная компрессия: доказательство в случае 1 ноды

- С двух предыдущих слайдов:

$$f(w_{k+1}) - \leq f(w_k) - \gamma \langle C(\nabla f(w_k)), \nabla f(w_k) \rangle + \frac{\gamma^2 L}{2} \|C(\nabla f(w_k))\|^2.$$

$$-\gamma \mathbb{E}_C [\langle C(\nabla f(w_k)), \nabla f(w_k) \rangle] + \frac{\gamma}{2} \mathbb{E}_C [\|C(\nabla f(w_k))\|^2] \leq -\frac{\gamma}{2\delta} \|\nabla f(w_k)\|^2.$$

## Смещенная компрессия: доказательство в случае 1 ноды

- С двух предыдущих слайдов:

$$f(w_{k+1}) - \leq f(w_k) - \gamma \langle C(\nabla f(w_k)), \nabla f(w_k) \rangle + \frac{\gamma^2 L}{2} \|C(\nabla f(w_k))\|^2.$$

$$-\gamma \mathbb{E}_C [\langle C(\nabla f(w_k)), \nabla f(w_k) \rangle] + \frac{\gamma}{2} \mathbb{E}_C [\|C(\nabla f(w_k))\|^2] \leq -\frac{\gamma}{2\delta} \|\nabla f(w_k)\|^2.$$

- Сложим, вычтем из обоих частей  $f(w^*)$  и возьмем полное мат. ожидание:

$$\begin{aligned}\mathbb{E}[f(w_{k+1}) - f(w^*)] &\leq \mathbb{E}[f(w_k) - f(w^*)] - \frac{\gamma}{2} (1 - \gamma L) \mathbb{E}[\|C(\nabla f(w_k))\|^2] \\ &\quad - \frac{\gamma}{2\delta} \mathbb{E}[\|\nabla f(w_k)\|^2].\end{aligned}$$

## Смещенная компрессия: доказательство в случае 1 ноды

- С двух предыдущих слайдов:

$$f(w_{k+1}) - \leq f(w_k) - \gamma \langle C(\nabla f(w_k)), \nabla f(w_k) \rangle + \frac{\gamma^2 L}{2} \|C(\nabla f(w_k))\|^2.$$

$$-\gamma \mathbb{E}_C [\langle C(\nabla f(w_k)), \nabla f(w_k) \rangle] + \frac{\gamma}{2} \mathbb{E}_C [\|C(\nabla f(w_k))\|^2] \leq -\frac{\gamma}{2\delta} \|\nabla f(w_k)\|^2.$$

- Сложим, вычтем из обоих частей  $f(w^*)$  и возьмем полное мат. ожидание:

$$\begin{aligned}\mathbb{E}[f(w_{k+1}) - f(w^*)] &\leq \mathbb{E}[f(w_k) - f(w^*)] - \frac{\gamma}{2} (1 - \gamma L) \mathbb{E}[\|C(\nabla f(w_k))\|^2] \\ &\quad - \frac{\gamma}{2\delta} \mathbb{E}[\|\nabla f(w_k)\|^2].\end{aligned}$$

- Возьмем  $\gamma \leq \frac{1}{L}$ :

$$\mathbb{E}[f(w_{k+1}) - f(w^*)] \leq \mathbb{E}[f(w_k) - f(w^*)] - \frac{\gamma}{2\delta} \mathbb{E}[\|\nabla f(w_k)\|^2].$$

## Смещенная компрессия: доказательство в случае 1 ноды

- С предыдущего слайда:

$$\mathbb{E}[f(w_{k+1}) - f(w^*)] \leq \mathbb{E}[f(w_k) - f(w^*)] - \frac{\gamma}{2\delta} \mathbb{E}[\|\nabla f(w_k)\|^2].$$

- С предыдущего слайда:

$$\mathbb{E}[f(w_{k+1}) - f(w^*)] \leq \mathbb{E}[f(w_k) - f(w^*)] - \frac{\gamma}{2\delta} \mathbb{E}[\|\nabla f(w_k)\|^2].$$

- Сильная выпуклость (или даже более слабое условие PL):

$$2\mu(f(w_k) - f(w^*)) \leq \|\nabla f(w_k)\|^2.$$

## Смещенная компрессия: доказательство в случае 1 ноды

- С предыдущего слайда:

$$\mathbb{E}[f(w_{k+1}) - f(w^*)] \leq \mathbb{E}[f(w_k) - f(w^*)] - \frac{\gamma}{2\delta} \mathbb{E}[\|\nabla f(w_k)\|^2].$$

- Сильная выпуклость (или даже более слабое условие PL):

$$2\mu(f(w_k) - f(w^*)) \leq \|\nabla f(w_k)\|^2.$$

- Соединим два предыдущих:

$$\mathbb{E}[f(w_{k+1}) - f(w^*)] \leq \left(1 - \frac{\gamma\mu}{\delta}\right) \mathbb{E}[f(w_k) - f(w^*)].$$

## Теорема (сходимость QGD со смещенной компрессией в случае 1 ноды)

Пусть  $f$   $\mu$ -сильно выпуклая (или PL) и имеет  $L$ -Липшицев градиент, тогда QGD для одной ноды с шагом  $\gamma \leq 1/L$  и со смещенным компрессором с параметром  $\delta$  сходится и выполнено:

$$f(w_K) - f(w^*) \leq \left(1 - \frac{\gamma\mu}{\delta}\right)^K (f(w_0) - f(w^*)).$$



Beznosikov A. et al. On Biased Compression for Distributed Learning

## Смещенная компрессия: не так все просто

- Рассмотрим следующую распределенную задачу с  $M = 3$ ,  $d = 3$  и локальными функциями:

$$f_1(w) = \langle a, w \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_2(w) = \langle b, x \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_3(w) = \langle c, w \rangle^2 + \frac{1}{4} \|w\|^2$$

где  $a = (-3, 2, 2)$ ,  $b = (2, -3, 2)$  и  $c = (2, 2, -3)$ .

## Смещенная компрессия: не так все просто

- Рассмотрим следующую распределенную задачу с  $M = 3$ ,  $d = 3$  и локальными функциями:

$$f_1(w) = \langle a, w \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_2(w) = \langle b, x \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_3(w) = \langle c, w \rangle^2 + \frac{1}{4} \|w\|^2$$

где  $a = (-3, 2, 2)$ ,  $b = (2, -3, 2)$  и  $c = (2, 2, -3)$ .

- Вопрос:** где у нее оптимум?

## Смещенная компрессия: не так все просто

- Рассмотрим следующую распределенную задачу с  $M = 3$ ,  $d = 3$  и локальными функциями:

$$f_1(w) = \langle a, w \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_2(w) = \langle b, x \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_3(w) = \langle c, w \rangle^2 + \frac{1}{4} \|w\|^2$$

где  $a = (-3, 2, 2)$ ,  $b = (2, -3, 2)$  и  $c = (2, 2, -3)$ .

- Вопрос:** где у нее оптимум?  $(0, 0, 0)$ .

## Смещенная компрессия: не так все просто

- Рассмотрим следующую распределенную задачу с  $M = 3$ ,  $d = 3$  и локальными функциями:

$$f_1(w) = \langle a, w \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_2(w) = \langle b, x \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_3(w) = \langle c, w \rangle^2 + \frac{1}{4} \|w\|^2$$

где  $a = (-3, 2, 2)$ ,  $b = (2, -3, 2)$  и  $c = (2, 2, -3)$ .

- Вопрос:** где у нее оптимум?  $(0, 0, 0)$ .
- Пусть стартовая точка  $w_0 = (t, t, t)$  для какого-то  $t > 0$ . Тогда локальные градиенты:

$$\nabla f_1(w_0) = \frac{t}{2}(-11, 9, 9), \quad \nabla f_2(w_0) = \frac{t}{2}(9, -11, 9), \quad \nabla f_3(w_0) = \frac{t}{2}(9, 9, -11).$$

- Вопрос:** как будет выглядеть шаг QGD (градиентного спуска с сжатиями), если мы будем использовать Top1 компрессию?

## Смещенная компрессия: не так все просто

- Рассмотрим следующую распределенную задачу с  $M = 3$ ,  $d = 3$  и локальными функциями:

$$f_1(w) = \langle a, w \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_2(w) = \langle b, x \rangle^2 + \frac{1}{4} \|w\|^2, \quad f_3(w) = \langle c, w \rangle^2 + \frac{1}{4} \|w\|^2$$

где  $a = (-3, 2, 2)$ ,  $b = (2, -3, 2)$  и  $c = (2, 2, -3)$ .

- Вопрос:** где у нее оптимум?  $(0, 0, 0)$ .
- Пусть стартовая точка  $w_0 = (t, t, t)$  для какого-то  $t > 0$ . Тогда локальные градиенты:

$$\nabla f_1(w_0) = \frac{t}{2}(-11, 9, 9), \quad \nabla f_2(w_0) = \frac{t}{2}(9, -11, 9), \quad \nabla f_3(w_0) = \frac{t}{2}(9, 9, -11).$$

- Вопрос:** как будет выглядеть шаг QGD (градиентного спуска с сжатиями), если мы будем использовать Top1 компрессию?

$$w_1 = (t, t, t) + \eta \cdot \frac{11}{6}(t, t, t) = \left(1 + \frac{11\eta}{6}\right)x_0.$$

- Мы удаляемся от решения геометрически для любого  $\eta > 0$ .



## Смещенная компрессия: компенсация ошибки

- Попробуем запоминать то, что не передали в процессе общения:

$$e_{1,m} = 0 + \gamma \nabla f_m(w_0) - C(0 + \gamma \nabla f_m(w_0)).$$

## Смещенная компрессия: компенсация ошибки

- Попробуем запоминать то, что не передали в процессе общения:

$$e_{1,m} = 0 + \gamma \nabla f_m(w_0) - C(0 + \gamma \nabla f_m(w_0)).$$

- И добавлять это в будущие посылки:

$$C(e_{1,m} + \gamma \nabla f_m(w_1))$$

## Смещенная компрессия: компенсация ошибки

- Попробуем запоминать то, что не передали в процессе общения:

$$e_{1,m} = 0 + \gamma \nabla f_m(w_0) - C(0 + \gamma \nabla f_m(w_0)).$$

- И добавлять это в будущие посылки:

$$C(e_{1,m} + \gamma \nabla f_m(w_1))$$

- На произвольной итерации это записывается так:

Посылка:  $C(e_{k,m} + \gamma \nabla f_m(w_k)),$

$$e_{k+1,m} = e_{k,m} + \gamma \nabla f_m(w_k) - C(e_{k,m} + \gamma \nabla f_m(w_k))$$

# Смещенная компрессия: компенсация ошибки

- Попробуем запоминать то, что не передали в процессе общения:

$$e_{1,m} = 0 + \gamma \nabla f_m(w_0) - C(0 + \gamma \nabla f_m(w_0)).$$

- И добавлять это в будущие посылки:

$$C(e_{1,m} + \gamma \nabla f_m(w_1))$$

- На произвольной итерации это записывается так:

Посылка:  $C(e_{k,m} + \gamma \nabla f_m(w_k)),$

$$e_{k+1,m} = e_{k,m} + \gamma \nabla f_m(w_k) - C(e_{k,m} + \gamma \nabla f_m(w_k))$$

- Это техника называется компенсация ошибки (error feedback).



Stich S. et al. Sparsified SGD with memory

## QGD c error feedback

### Algorithm QGD c error feedback

**Вход:** Размер шага  $\gamma > 0$ , стартовая точка  $w_0 \in \mathbb{R}^d$ , стартовые ошибки  $e_{0,m} = 0$  для всех  $m$  от 1 до  $M$ , количество итераций  $K$


- ```

1: for  $k = 0, 1, \dots, K - 1$  do
2:   Отправить  $x_k$  всем рабочим                                ▷ выполняется сервером
3:   for  $m = 1, \dots, M$  параллельно do
4:     Принять  $w_k$  от мастера                               ▷ выполняется рабочими
5:     Вычислить градиент  $\nabla f(w_k)$  в точке  $w_k$     ▷ выполняется рабочими
6:     Сгенерировать  $g_{k,m} = C(e_{k,m} + \gamma \nabla f(w_k))$  ▷ выполняется рабочими
7:     Вычислить  $e_{k+1,m} = e_{k,m} + \gamma \nabla f_m(w_k) - g_{k,m}$  ▷ выполняется
      рабочими
8:     Отправить  $g_{k,m}$  мастеру                           ▷ выполняется рабочими
9:   end for
10:  Принять  $g_{k,m}$  от всех рабочих                      ▷ выполняется сервером
11:  Вычислить  $g_k = \frac{1}{M} \sum_{m=1}^M g_{k,m}$           ▷ выполняется сервером
12:   $w_{k+1} = w_k - g_k$                                  ▷ выполняется сервером
13: end for

```

**Выход:**  $w_K$

## QGD с error feedback: сходимость



**Рисунок:** Точность в ходе обучения VGG19 на CIFAR10 с использованием разных компрессоров

## Теорема GD с error feedback

Пусть все локальные функции  $f_m$  являются  $\mu$ -сильно выпуклыми и имеют  $L$ -Липшицев градиент, тогда если  $\eta \leq \frac{1}{28\delta L}$ , то

$$\begin{aligned}\mathbb{E}[f(\tilde{x}_K) - f(x^*)] &\leq \mathcal{O} \left( \delta L \|x_0 - x^*\|^2 \exp \left( -\frac{\gamma\mu K}{2} \right) \right. \\ &\quad \left. + \frac{\delta}{\mu K} \cdot \frac{1}{M} \sum_{m=1}^M \|\nabla f_m(x^*)\|^2 \right).\end{aligned}$$

 Stich S. and Karimireddy S. The error-feedback framework: Better rates for SGD with delayed gradients and compressed communication

 Beznosikov A. et al. On Biased Compression for Distributed Learning

- Та же самая проблема, что и у QGD – второй член в оценке по-хорошему нужно устраниТЬ.

- Идя похожа на DIANA: память + сжатие разности

---

## Algorithm EF21 (скетч)

---

- Каждое устройство  $m$  обладает вектором "памяти"  $g_0^m = 0$
  - Сервер хранит  $h_0 = \frac{1}{M} \sum_{m=1}^M h_0^m = 0$
  - Досылаем на сервер сжатую версию разницы  $C(\nabla f_m(w^k) - h_k^m)$
  - Обновляем память  $h_{k+1}^m = h_k^m + C(\nabla f_m(w^k) - h_k^m)$
  - Сервер вычисляет  $h_{k+1} = h_k + \frac{1}{M} \sum_{m=1}^M C(\nabla f_m(w^k) - h_k^m)$
  - Для апдейта  $w_{k+1} = w_k - \gamma h_{k+1}$
- 



Richtarik P. et al. EF21: A New, Simpler, Theoretically Better, and Practically Faster Error Feedback

## Несмешенная против смещенной

- Лучшая оценка на число коммуникаций для неускоренного метода с несмешенной компрессией (DIANA):

$$\mathcal{O} \left( \left[ 1 + \frac{\omega}{M} \right] \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Лучшая оценка на число коммуникаций для неускоренного метода со смещенной компрессией (EF-21):

$$\mathcal{O} \left( [1 + \delta] \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Уже обсуждалось, что эти оценки хуже, чем для базового GD.

## Несмешенная против смешенной

- Компрессоры сжимают информацию в  $\beta$  раз и типично, что  $\beta \geq \omega$  и  $\beta \geq \delta$ .

## Несмешенная против смещенной

- Компрессоры сжимают информацию в  $\beta$  раз и типично, что  $\beta \geq \omega$  и  $\beta \geq \delta$ .
- Лучшая оценка на число информации для неускоренного метода с несмешенной компрессией (DIANA):

$$\mathcal{O} \left( \left[ \frac{1}{\beta} + \frac{1}{M} \right] \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Как уже обсуждалось, несмешенный компрессор доказуемо улучшает число передаваемой информации.

## Несмешенная против смешенной

- Компрессоры сжимают информацию в  $\beta$  раз и типично, что  $\beta \geq \omega$  и  $\beta \geq \delta$ .
- Лучшая оценка на число информации для неускоренного метода с несмешенной компрессией (DIANA):

$$\mathcal{O}\left(\left[\frac{1}{\beta} + \frac{1}{M}\right] \frac{L}{\mu} \log \frac{1}{\varepsilon}\right).$$

- Как уже обсуждалось, несмешенный компрессор доказуемо улучшает число передаваемой информации.
- Смешенный компрессор имеет оценку:

$$\mathcal{O}\left(\left[\frac{1}{\beta} + \frac{\delta}{\beta}\right] \frac{L}{\mu} \log \frac{1}{\varepsilon}\right).$$

- Смешенный компрессор не улучшает число передаваемой информации в общем случае. И это открытый вопрос: как увидеть теоретическое превосходство смешенных операторов, которое часто проявляется на практике.

# Локальный подход

# Идея – больше локальных вычислений

- В базовом подходе коммуникации происходят каждую итерацию.
- Если считать (стохастические) градиенты значительно дешевле, почему бы не считать несколько раз между коммуникациями.

# Локальный градиентный спуск

Идея метода:


- Делать локальные шаги:

$$x_m^{k+1} = x_m^k - \gamma \nabla f_m(x_m^k, \xi_m^k).$$

- Каждую  $t$ ую итерацию пересылать текущий  $x_m^k$  на сервер. Сервер усредняет  $x^k = \frac{1}{M} \sum_{m=1}^M x_m^k$ , и пересыпает  $x^k$  устройствам.  
Устройства обновляют:  $x_m^k = x^k$ .
- Централизованный SGD это Локальный SGD с  $K = 1$ .

# Сходимость

- Типичная сходимость такого типа методов:



**Рисунок:** Сходимость Локального метода на практике для логистической регрессии.

- Быстрее с точки зрения коммуникаций, хуже качество придельной точности.



Khaled A. et al. Tighter Theory for Local SGD on Identical and Heterogeneous Data

# Сходимость

- **Вопрос:** из-за чего возникает такой эффект? Он возникает из-за разнородности локальных данных на разных устройствах.
- В верхних оценках сходимости метода это тоже проявляется:

$$\mathcal{O} \left( \frac{\|x^0 - x^*\|^2}{\gamma T} + \frac{\gamma \sigma_{opt}^2}{M} \right),$$

где  $\gamma \leq \mathcal{O} \left( \frac{1}{L t} \right)$  – шаг,  $K$  – кол-во локальных итераций на каждом устройстве. Оценка дана для случая выпуклых и  $L$ -гладких  $f_m$ .



Khaled A. et al. Tighter Theory for Local SGD on Identical and Heterogeneous Data

- Более того, фактор  $\sigma_{opt}^2$  не устраняется.



Glasgow M.R. et al. Sharp bounds for federated averaging (local sgd) and continuous perspective

# Физика проблемы

- Далеко от решения:
- Близко к решению:

# Решаем проблему

- **Вопрос:** проблема локального метода – сходимость к окрестности. Как ее можно решить?

# Решаем проблему

- **Вопрос:** проблема локального метода – сходимость к окрестности. Как ее можно решить?
- Регуляризация локальной задачи:

$$\tilde{f}_m(x) := f_m(x) + \frac{\lambda}{2} \|x - v\|^2,$$

где  $v$  – некоторая референсная точка.

Karimireddy S. P. SCAFFOLD: Stochastic Controlled Averaging for Federated Learning



# А вообще чего хотим достичь?

- Нижние оценки:

$$K = \Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{1}{\varepsilon}\right).$$

$L$  и  $\mu$  – константы гладкости и сильной выпуклости  $f$ .

- Вопрос: какой метод даст такие оценки?

# А вообще чего хотим достичь?

- Нижние оценки:

$$K = \Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{1}{\varepsilon}\right).$$

$L$  и  $\mu$  – константы гладкости и сильной выпуклости  $f$ .

- **Вопрос:** какой метод даст такие оценки? Распределенная версия метода Нестерова с 1 локальным шагом между коммуникациями.
- Отметим, что локальные методы стали для стохастических постановок.

# А вообще чего хотим достичь?

- Нижние оценки:

$$K = \Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{1}{\varepsilon}\right).$$

$L$  и  $\mu$  – константы гладкости и сильной выпуклости  $f$ .

- **Вопрос:** какой метод даст такие оценки? Распределенная версия метода Нестерова с 1 локальным шагом между коммуникациями.
- Отметим, что локальные методы стали для стохастических постановок.
- Но и тут в общем случае нет улучшений.  
 Woodworth B. The Min-Max Complexity of Distributed Stochastic Convex Optimization with Intermittent Communication
- Но есть постановки, где локальные методы выстреливают.

## Data similarity

# Data similarity

- Распределенная задача обучения:

$$f(w) = \frac{1}{M} \sum_{m=1}^M f_m(w) = \frac{1}{M} \sum_{m=1}^M \left[ \frac{1}{N} \sum_{i=1}^N \ell(w, z_i) \right],$$

где  $z_i$  – элемент выборки  $(x_i, y_i)$ ,  $\ell$  – функция потерь (в нее входят  $f$  и  $g$ ).

# Data similarity

- Распределенная задача обучения:

$$f(w) = \frac{1}{M} \sum_{m=1}^M f_m(w) = \frac{1}{M} \sum_{m=1}^M \left[ \frac{1}{N} \sum_{i=1}^N \ell(w, z_i) \right],$$

где  $z_i$  – элемент выборки  $(x_i, y_i)$ ,  $\ell$  – функция потерь (в нее зашита  $f$  и  $g$ ).

- Предположим, что мы можем разбить обучающую выборку равномерно между устройствами (например, если используются кластерные или коллаборативные вычисления на открытых данных).

# Data similarity

- Распределенная задача обучения:

$$f(w) = \frac{1}{M} \sum_{m=1}^M f_m(w) = \frac{1}{M} \sum_{m=1}^M \left[ \frac{1}{N} \sum_{i=1}^N \ell(w, z_i) \right],$$

где  $z_i$  – элемент выборки  $(x_i, y_i)$ ,  $\ell$  – функция потерь (в нее зашита  $f$  и  $g$ ).

- Предположим, что мы можем разбить обучающую выборку равномерно между устройствами (например, если используются кластерные или коллаборативные вычисления на открытых данных).
- Это дает похожесть локальных функций потерь.

# Data similarity

- Распределенная задача обучения:

$$f(w) = \frac{1}{M} \sum_{m=1}^M f_m(w) = \frac{1}{M} \sum_{m=1}^M \left[ \frac{1}{N} \sum_{i=1}^N \ell(w, z_i) \right],$$

где  $z_i$  – элемент выборки  $(x_i, y_i)$ ,  $\ell$  – функция потерь (в нее зашита  $f$  и  $g$ ).

- Предположим, что мы можем разбить обучающую выборку равномерно между устройствами (например, если используются кластерные или коллаборативные вычисления на открытых данных).
- Это дает похожесть локальных функций потерь.
- Утверждается, что для любого  $w$

$$\|\nabla^2 f_m(w) - \nabla^2 f(w)\| \leq \delta.$$

# Матричное неравенство Хёфдинга

## Теорема (Матричное неравенство Хёфдинга)

Рассмотрим конечную последовательность случайных квадратных матриц  $\{X_i\}_{i=1}^N$ . Пусть в этой последовательности матрицы независимы, эрмитовы и имеют размерность  $d$ . Предположим так же, что  $\mathbb{E}[X_i] = 0$ , и  $X_i^2 \preceq A^2$  почти наверное, где  $A$  – неслучайная эрмитова матрица. Тогда с вероятностью  $1 - p$  выполнено, что

$$\left\| \sum_{i=1}^N X_i \right\| \leq \sqrt{8N\|A^2\| \cdot \ln(d/p)}.$$



Tropp J. An introduction to matrix concentration inequalities

Tropp J. User-friendly tail bounds for sums of random matrices

# Параметр схожести

- Локальная функция потерь:

$$f_m(w) = \frac{1}{N} \sum_{i=1}^N \ell(w, z_i).$$

- $\ell$  –  $L$ -гладкая ( $L$ -Липшицев градиент), выпуклая, дважды дифференцируемая функция (например, квадратичная или логрегрессия). Тогда имеем  $\nabla^2 \ell(w, z_i) \preceq L I$  для любого  $w$  и  $z_i$  (здесь  $I$  – единичная матрица.).
- Распределим все данные равномерно по всем нодам.  
 $X_i = \frac{1}{N} [\nabla \ell(w, z_i) - \nabla f(w)]$ . Легко проверить, что все условия матричного неравенства Хёфдинга для нее выполнены, в частности,  $A^2 = \frac{4L^2}{N^2} I$ .

## Параметр схожести: итог

- В итоге имеем

$$\|\nabla^2 f_m(w) - \nabla^2 f(w)\| \leq \delta \sim \frac{L}{\sqrt{N}}.$$

## Параметр схожести: итог

- В итоге имеем

$$\|\nabla^2 f_m(w) - \nabla^2 f(w)\| \leq \delta \sim \frac{L}{\sqrt{N}}.$$

- Для квадратичных задач можно получить оценку вида:

$$\|\nabla^2 f_m(w) - \nabla^2 f(w)\| \leq \delta \sim \frac{L}{N}.$$



Hendrikx H. et al. Statistically Preconditioned Accelerated Gradient Method for Distributed Optimization

## Параметр схожести: итог

- В итоге имеем

$$\|\nabla^2 f_m(w) - \nabla^2 f(w)\| \leq \delta \sim \frac{L}{\sqrt{N}}.$$

- Для квадратичных задач можно получить оценку вида:

$$\|\nabla^2 f_m(w) - \nabla^2 f(w)\| \leq \delta \sim \frac{L}{N}.$$



Hendrikx H. et al. Statistically Preconditioned Accelerated Gradient Method for Distributed Optimization

- В любом случае следует вывод: чем больше размер локальной выборки, тем меньше параметр схожести (похожи между собой гессианы).

# Метод в общем виде

- Рассмотрим зеркальный спуск:

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} (\gamma \langle \nabla f(w_k), w \rangle + V(w, w_k)),$$

где  $V(x, y)$  – дивергенция Брегмана, порожденная функцией строго-выпуклой функцией  $\varphi(x)$ :

$$V(x, y) = \varphi(x) - \varphi(y) - \langle \nabla \varphi(y); x - y \rangle.$$

# Метод в общем виде

- Рассмотрим зеркальный спуск:

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} (\gamma \langle \nabla f(w_k), w \rangle + V(w, w_k)),$$

где  $V(x, y)$  – дивергенция Брегмана, порожденная функцией строго-выпуклой функцией  $\varphi(x)$ :

$$V(x, y) = \varphi(x) - \varphi(y) - \langle \nabla \varphi(y); x - y \rangle.$$

- Вопрос:** Какой метод получится, если  $\varphi(x) = \frac{1}{2}\|x\|^2$ ?

# Метод в общем виде

- Рассмотрим зеркальный спуск:

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} (\gamma \langle \nabla f(w_k), w \rangle + V(w, w_k)),$$

где  $V(x, y)$  – дивергенция Брегмана, порожденная функцией строго-выпуклой функцией  $\varphi(x)$ :

$$V(x, y) = \varphi(x) - \varphi(y) - \langle \nabla \varphi(y); x - y \rangle.$$

- Вопрос:** Какой метод получится, если  $\varphi(x) = \frac{1}{2}\|x\|^2$ ?  
Градиентный спуск.

# Сходимость в общем виде

Определение (относительная гладкость и сильная выпуклость)

Пусть  $\varphi : \mathbb{R}^d \rightarrow \mathbb{R}$  является выпуклой и дважды дифференцируемой. Будем говорить, что функция  $f$  является  $L_\varphi$ -гладкой и  $\mu_\varphi$ -сильно выпуклой относительно  $\varphi$ , если для любого  $x \in \mathbb{R}^d$  выполнено

$$\mu_\varphi \nabla^2 \varphi(x) \preceq \nabla^2 f(x) \preceq L_\varphi \nabla^2 \varphi(x),$$

или эквивалентно для любых  $x, y \in \mathbb{R}^d$

$$\mu_\varphi V(x, y) \leq f(x) - f(y) - \langle \nabla f(y); x - y \rangle \leq L_\varphi V(x, y).$$



Lu H. et al. Relatively-Smooth Convex Optimization by First-Order Methods, and Applications

## Сходимость в общем виде: доказательство

- Первое условие оптимальности для шага зеркального спуска:

$$\gamma \nabla f(w_k) + \nabla \varphi(w_{k+1}) - \nabla \varphi(w_k) = 0.$$

## Сходимость в общем виде: доказательство

- Первое условие оптимальности для шага зеркального спуска:

$$\gamma \nabla f(w_k) + \nabla \varphi(w_{k+1}) - \nabla \varphi(w_k) = 0.$$

- Из него (здесь  $w^*$  – оптимум):

$$\langle \gamma \nabla f(w_k) + \nabla \varphi(w_{k+1}) - \nabla \varphi(w_k), w_{k+1} - w^* \rangle = 0.$$

$$\begin{aligned}\langle \gamma \nabla f(w_k), w^{k+1} - w^* \rangle &= \langle \nabla \varphi(w_k) - \nabla \varphi(w_{k+1}), w^{k+1} - w^* \rangle \\ &= V(w^*, w_k) - V(w^*, w_{k+1}) - V(w_{k+1}, w_k).\end{aligned}$$

(последнее утверждение называется теоремой Пифагора для дивергенций Брегмана и проверяется по определению)

## Сходимость в общем виде: доказательство

- Первое условие оптимальности для шага зеркального спуска:

$$\gamma \nabla f(w_k) + \nabla \varphi(w_{k+1}) - \nabla \varphi(w_k) = 0.$$

- Из него (здесь  $w^*$  – оптимум):

$$\langle \gamma \nabla f(w_k) + \nabla \varphi(w_{k+1}) - \nabla \varphi(w_k), w_{k+1} - w^* \rangle = 0.$$

$$\begin{aligned}\langle \gamma \nabla f(w_k), w^{k+1} - w^* \rangle &= \langle \nabla \varphi(w_k) - \nabla \varphi(w_{k+1}), w^{k+1} - w^* \rangle \\ &= V(w^*, w_k) - V(w^*, w_{k+1}) - V(w_{k+1}, w_k).\end{aligned}$$

(последнее утверждение называется теоремой Пифагора для дивергенций Брегмана и проверяется по определению)

- Небольшие перестановки дадут:

$$\begin{aligned}\langle \gamma \nabla f(w_k), w_{k+1} - w_k \rangle + V(w_{k+1}, w_k) \\ &= V(w^*, w_k) - V(w^*, w_{k+1}) - \langle \gamma \nabla f(w_k), w_k - w^* \rangle.\end{aligned}$$

## Сходимость в общем виде: доказательство

- Подставим  $\gamma = \frac{1}{L_\varphi}$ :

$$\begin{aligned}\langle \nabla f(w_k), w^{k+1} - w^k \rangle + L_\varphi V(w_{k+1}, w_k) \\ = L_\varphi V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}) \\ - \langle \nabla f(w_k), w_k - w^* \rangle.\end{aligned}$$

## Сходимость в общем виде: доказательство

- Подставим  $\gamma = \frac{1}{L_\varphi}$ :

$$\begin{aligned}\langle \nabla f(w_k), w^{k+1} - w^k \rangle + L_\varphi V(w_{k+1}, w_k) \\ = L_\varphi V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}) \\ - \langle \nabla f(w_k), w_k - w^* \rangle.\end{aligned}$$

- Воспользуемся определением гладкость относительно  $\varphi$  с  $x = w_{k+1}$ ,  $y = w_k$ :

$$f(w_{k+1}) - f(w_k) \leq \langle \nabla f(w_k); w_{k+1} - w_k \rangle + L_\varphi V(w_{k+1}, w_k).$$

## Сходимость в общем виде: доказательство

- Подставим  $\gamma = \frac{1}{L_\varphi}$ :

$$\begin{aligned}\langle \nabla f(w_k), w^{k+1} - w^k \rangle + L_\varphi V(w_{k+1}, w_k) \\ = L_\varphi V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}) \\ - \langle \nabla f(w_k), w_k - w^* \rangle.\end{aligned}$$

- Воспользуемся определением гладкость относительно  $\varphi$  с  $x = w_{k+1}$ ,  $y = w_k$ :

$$f(w_{k+1}) - f(w_k) \leq \langle \nabla f(w_k); w_{k+1} - w_k \rangle + L_\varphi V(w_{k+1}, w_k).$$

- Соединим два предыдущих:

$$f(w_{k+1}) - f(w_k) \leq L_\varphi V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}) - \langle \nabla f(w_k), w_k - w^* \rangle$$

## Сходимость в общем виде: доказательство

- С предыдущего слайда:

$$\begin{aligned} f(w_{k+1}) - f(w_k) &\leq L_\varphi V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}) \\ &\quad - \langle \nabla f(w_k), w_k - w^* \rangle. \end{aligned}$$

## Сходимость в общем виде: доказательство

- С предыдущего слайда:

$$\begin{aligned} f(w_{k+1}) - f(w_k) &\leq L_\varphi V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}) \\ &\quad - \langle \nabla f(w_k), w_k - w^* \rangle. \end{aligned}$$

- Относительная сильная выпуклость:

$$\mu_\varphi V(w^*, w_k) \leq f(w^*) - f(w_k) - \langle \nabla f(w_k); w^* - w_k \rangle$$

## Сходимость в общем виде: доказательство

- С предыдущего слайда:

$$\begin{aligned} f(w_{k+1}) - f(w_k) &\leq L_\varphi V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}) \\ &\quad - \langle \nabla f(w_k), w_k - w^* \rangle. \end{aligned}$$

- Относительная сильная выпуклость:

$$\mu_\varphi V(w^*, w_k) \leq f(w^*) - f(w_k) - \langle \nabla f(w_k); w^* - w_k \rangle$$

- Сложим два предыдущих и немного перемещаем:

$$f(w_{k+1}) - f(w^*) \leq (L_\varphi - \mu_\varphi) V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}).$$

## Сходимость в общем виде: доказательство

- С предыдущего слайда:

$$f(w_{k+1}) - f(w_k) \leq L_\varphi V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}) \\ - \langle \nabla f(w_k), w_k - w^* \rangle.$$

- Относительная сильная выпуклость:

$$\mu_\varphi V(w^*, w_k) \leq f(w^*) - f(w_k) - \langle \nabla f(w_k); w^* - w_k \rangle$$

- Сложим два предыдущих и немного перемещаем:

$$f(w_{k+1}) - f(w^*) \leq (L_\varphi - \mu_\varphi) V(w^*, w_k) - L_\varphi V(w^*, w_{k+1}).$$

- В силу того, что  $w^*$  – оптимум:

$$V(w^*, w_{k+1}) \leq \left(1 - \frac{\mu_\varphi}{L_\varphi}\right) V(w^*, w_k).$$

# Сходимость в общем виде: теорема

## Теорема (сходимость зеркального спуска)

Пусть  $\varphi$  и  $f$  удовлетворяют определению выше, тогда зеркальный спуск с шагом  $\gamma = \frac{1}{L_\varphi}$  сходится и выполнено:

$$V(w^*, w_K) \leq \left(1 - \frac{\mu_\varphi}{L_\varphi}\right)^K V(w^*, w_0).$$



Lu H. et al. Relatively-Smooth Convex Optimization by First-Order Methods, and Applications

# Метод для задачи data similarity

- Зеркальный спуск:

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} (\gamma \langle \nabla f(w_k), w \rangle + V(w, w_k)),$$

где с дивергенция Брегмана  $V(x, y)$ , порожденной функцией  $\varphi(x)$  (тут нужно потребовать, чтобы  $f_1$  была выпуклой):

$$\varphi(x) = f_1(x) + \frac{\delta}{2} \|x\|^2.$$

Функция  $f_1$  хранится на сервере.

# Метод для задачи data similarity

- Зеркальный спуск:

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} (\gamma \langle \nabla f(w_k), w \rangle + V(w, w_k)),$$

где с дивергенция Брегмана  $V(x, y)$ , порожденной функцией  $\varphi(x)$  (тут нужно потребовать, чтобы  $f_1$  была выпуклой):

$$\varphi(x) = f_1(x) + \frac{\delta}{2} \|x\|^2.$$

Функция  $f_1$  хранится на сервере.

- **Вопрос:** Какое число коммуникаций происходит за  $K$  итераций такого зеркального спуска?

# Метод для задачи data similarity

- Зеркальный спуск:

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} (\gamma \langle \nabla f(w_k), w \rangle + V(w, w_k)),$$

где с дивергенция Брегмана  $V(x, y)$ , порожденной функцией  $\varphi(x)$  (тут нужно потребовать, чтобы  $f_1$  была выпуклой):

$$\varphi(x) = f_1(x) + \frac{\delta}{2} \|x\|^2.$$

Функция  $f_1$  хранится на сервере.

- **Вопрос:** Какое число коммуникаций происходит за  $K$  итераций такого зеркального спуска?  $K$  коммуникаций (количество подсчетов градиента  $\nabla f$ ), вычисления  $\arg \min$  требуют только вычислений на сервере.

## Метод для задачи data similarity

#### Algorithm Зеркальный спуск для задачи data similarity

**Вход:** Размер шага  $\gamma > 0$ , стартовая точка  $w^0 \in \mathbb{R}^d$ , количество итераций  $K$

- ```

1: for  $k = 0, 1, \dots, K - 1$  do
2:   Отправить  $x_k$  всем рабочим           ▷ выполняется сервером
3:   for  $m = 1, \dots, M$  параллельно do
4:     Принять  $w_k$  от мастера           ▷ выполняется рабочими
5:     Вычислить градиент  $\nabla f_m(w_k)$  в точке  $w_k$  ▷ выполняется рабочими
6:     Отправить  $\nabla f_m(w_k)$  мастеру      ▷ выполняется рабочими
7:   end for
8:   Принять  $\nabla f_m(w_k)$  от всех рабочих    ▷ выполняется сервером
9:   Вычислить  $\nabla f(w_k) = \frac{1}{M} \sum_{m=1}^M \nabla f_m(w_k)$     ▷ выполняется сервером
10:   $w_{k+1} = \arg \min_{w \in \mathbb{R}^d} (\gamma \langle \nabla f(w_k), x \rangle + V(w, w_k))$     ▷ выполняется
    сервером
11: end for
Выход:  $w_K$ 

```

## Сходимость для задачи data similarity: доказательство

- Напомним, что сходимость определяется через константы из соотношения:

$$\mu_\varphi \nabla^2 \varphi(w) \preceq \nabla^2 f(w) \preceq L_\varphi \nabla^2 \varphi(w),$$

## Сходимость для задачи data similarity: доказательство

- Напомним, что сходимость определяется через константы из соотношения:

$$\mu_\varphi \nabla^2 \varphi(w) \preceq \nabla^2 f(w) \preceq L_\varphi \nabla^2 \varphi(w),$$

- В нашем случае:

$$\mu_\varphi (\delta I + \nabla^2 f_1(w)) \preceq \nabla^2 f(w) \preceq L_\varphi (\delta I + \nabla^2 f_1(w))$$

## Сходимость для задачи data similarity: доказательство

- Напомним, что сходимость определяется через константы из соотношения:

$$\mu_\varphi \nabla^2 \varphi(w) \preceq \nabla^2 f(w) \preceq L_\varphi \nabla^2 \varphi(w),$$

- В нашем случае:

$$\mu_\varphi (\delta I + \nabla^2 f_1(w)) \preceq \nabla^2 f(w) \preceq L_\varphi (\delta I + \nabla^2 f_1(w))$$

- Найдем  $L_\varphi$ :

$$\begin{aligned} \|\nabla^2 f_1(w) - \nabla^2 f(w)\| &\leq \delta \Rightarrow \nabla^2 f(w) - \nabla^2 f_1(w) \preceq \delta I \\ &\Rightarrow \nabla^2 f(w) \preceq \delta I + \nabla^2 f_1(w) \Rightarrow L_\varphi = 1. \end{aligned}$$

## Сходимость для задачи data similarity: доказательство

- Напомним, что сходимость определяется через константы из соотношения:

$$\mu_\varphi \nabla^2 \varphi(w) \preceq \nabla^2 f(w) \preceq L_\varphi \nabla^2 \varphi(w),$$

- В нашем случае:

$$\mu_\varphi (\delta I + \nabla^2 f_1(w)) \preceq \nabla^2 f(w) \preceq L_\varphi (\delta I + \nabla^2 f_1(w))$$

- Найдем  $L_\varphi$ :

$$\begin{aligned} \|\nabla^2 f_1(w) - \nabla^2 f(w)\| &\leq \delta \Rightarrow \nabla^2 f(w) - \nabla^2 f_1(w) \preceq \delta I \\ &\Rightarrow \nabla^2 f(w) \preceq \delta I + \nabla^2 f_1(w) \Rightarrow L_\varphi = 1. \end{aligned}$$

## Сходимость для задачи data similarity: доказательство

- Найдем  $\mu_\varphi$ . Из сильно выпуклости функции  $f$ :

$$\mu I \preceq \nabla^2 f(w) \Rightarrow \delta I \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

- Из  $\|\nabla^2 f_1(w) - \nabla^2 f(w)\| \leq \delta$  имеем:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \delta I.$$

- Объединяем два предыдущих пункта:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

- Откуда:

$$\nabla^2 f_1(w) + \delta I \preceq \frac{2\delta + \mu}{\mu} \nabla^2 f(w) \Rightarrow \mu_\varphi = \frac{\mu}{2\delta + \mu}.$$

## Сходимость для задачи data similarity: доказательство

- Найдем  $\mu_\varphi$ . Из сильно выпуклости функции  $f$ :

$$\mu I \preceq \nabla^2 f(w) \Rightarrow \delta I \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

## Сходимость для задачи data similarity: доказательство

- Найдем  $\mu_\varphi$ . Из сильно выпуклости функции  $f$ :

$$\mu I \preceq \nabla^2 f(w) \Rightarrow \delta I \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

- Из  $\|\nabla^2 f_1(w) - \nabla^2 f(w)\| \leq \delta$  имеем:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \delta I.$$

## Сходимость для задачи data similarity: доказательство

- Найдем  $\mu_\varphi$ . Из сильно выпуклости функции  $f$ :

$$\mu I \preceq \nabla^2 f(w) \Rightarrow \delta I \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

- Из  $\|\nabla^2 f_1(w) - \nabla^2 f(w)\| \leq \delta$  имеем:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \delta I.$$

- Объединяем два предыдущих пункта:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

## Сходимость для задачи data similarity: доказательство

- Найдем  $\mu_\varphi$ . Из сильно выпуклости функции  $f$ :

$$\mu I \preceq \nabla^2 f(w) \Rightarrow \delta I \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

- Из  $\|\nabla^2 f_1(w) - \nabla^2 f(w)\| \leq \delta$  имеем:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \delta I.$$

- Объединяем два предыдущих пункта:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

- Откуда:

$$\nabla^2 f_1(w) + \delta I \preceq \frac{2\delta + \mu}{\mu} \nabla^2 f(w) \Rightarrow \mu_\varphi = \frac{\mu}{2\delta + \mu}.$$

## Сходимость для задачи data similarity: доказательство

- Найдем  $\mu_\varphi$ . Из сильно выпуклости функции  $f$ :

$$\mu I \preceq \nabla^2 f(w) \Rightarrow \delta I \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

- Из  $\|\nabla^2 f_1(w) - \nabla^2 f(w)\| \leq \delta$  имеем:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \delta I.$$

- Объединяем два предыдущих пункта:

$$\nabla^2 f_1(w) - \nabla^2 f(w) \preceq \frac{2\delta}{\mu} \nabla^2 f(w) - \delta I.$$

- Откуда:

$$\nabla^2 f_1(w) + \delta I \preceq \frac{2\delta + \mu}{\mu} \nabla^2 f(w) \Rightarrow \mu_\varphi = \frac{\mu}{2\delta + \mu}.$$

# Сходимость для задачи data similarity: теорема

## Теорема (сходимость для задачи data similarity)

Пусть  $f$  сильно выпуклая,  $f_i$  выпуклые, а  $\ell$  - гладкие, а  
 $\varphi(w) = f_1(w) + \delta\|w\|^2$ , тогда зеркальный спуск с шагом  $\gamma = 1$   
сходится и выполнено:

$$V(w^*, w_K) \leq \left(1 - \frac{\mu}{\mu + 2\delta}\right)^K V(w^*, w_0).$$

# Сходимость для задачи data similarity: теорема

## Теорема (сходимость для задачи data similarity)

Пусть  $f$  сильно выпуклая,  $f_i$  выпуклые, а  $\ell$  - гладкие, а  $\varphi(w) = f_1(w) + \delta\|w\|^2$ , тогда зеркальный спуск с шагом  $\gamma = 1$  сходится и выполнено:

$$V(w^*, w_K) \leq \left(1 - \frac{\mu}{\mu + 2\delta}\right)^K V(w^*, w_0).$$

- Это означает, что если нам необходимо достичнуть точности  $\varepsilon$  ( $V(w^*, w_K) \sim \varepsilon$ ), то нам необходимо

$$K = \left( \left[ 1 + \frac{\delta}{\mu} \right] \log \frac{V(w^*, w_0)}{\varepsilon} \right) \text{ коммуникаций.}$$

# Лучше?

- Оценка на число коммуникаций в условиях data similarity:

$$K = \mathcal{O} \left( \left[ 1 + \frac{\delta}{\mu} \right] \log \frac{1}{\varepsilon} \right).$$

- Оценка на число коммуникаций для обычного распределенного градиентного спуска:

$$K = \mathcal{O} \left( \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

# Лучше?

- Оценка на число коммуникаций в условиях data similarity:

$$K = \mathcal{O} \left( \left[ 1 + \frac{\delta}{\mu} \right] \log \frac{1}{\varepsilon} \right).$$

- Оценка на число коммуникаций для обычного распределенного градиентного спуска:

$$K = \mathcal{O} \left( \frac{L}{\mu} \log \frac{1}{\varepsilon} \right).$$

- Напомним, что  $\delta \sim \frac{L}{\sqrt{N}}$ , т.е. может быть значительное улучшение.

# Другой взгляд на зеркальный спуск

- Зеркальный спуск с  $\gamma = 1$ :

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} (\langle \nabla f(w_k), w \rangle + V(w, w_k)),$$

где с дивергенция Брегмана  $V(x, y)$ , порожденной функцией  $\varphi(x)$ :

$$\varphi(x) = f_1(x) + \frac{\delta}{2} \|x\|^2.$$

- Подставим  $\varphi(x)$ :

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} \left( f_1(w) + \langle \nabla f(w_k) - \nabla f_1(w_k), w \rangle + \frac{\delta}{2} \|w - w_k\|^2 \right).$$

- Или чуть по-другому:

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} \left( \frac{1}{\delta} f_1(w) + \frac{1}{2} \left\| w - \left( w_k - \frac{1}{\delta} (\nabla f(w_k) - \nabla f_1(w_k)) \right) \right\|^2 \right)$$

# Итого про зеркальный спуск

- Всплыла идея регуляризации локальной подзадачи.
- Всплыла идея слайдинга  $\approx$  проксимального метода с неточностью.
- Проксимальный метод для композитной целевой функции  $g_1(w) + g_2(w)$ :

$$w_{k+1} = \arg \min_{w \in \mathbb{R}^d} \left( \gamma g_2(w) + \frac{1}{2} \|w - (w_k - \gamma g_1(w_k))\|^2 \right).$$

- В нашем случае,  $g_1 = f - f_1$ ,  $g_2 = f_1$ .

# Лучше?

- Мы получили:

$$K = \mathcal{O} \left( \left[ 1 + \frac{\delta}{\mu} \right] \log \frac{1}{\varepsilon} \right).$$

- Но есть ведь и ускоренный градиентный метод, который дает оценки:

$$K = \mathcal{O} \left( \sqrt{\frac{L}{\mu}} \log \frac{1}{\varepsilon} \right).$$

- Непонятно, что лучше. Более того, можно ли ускорить метод для задачи с data similarity?
- Для задачи data similarity так же имеются нижние оценки:

$$K = \Omega \left( \sqrt{1 + \frac{\delta}{\mu}} \log \frac{1}{\varepsilon} \right),$$

т.е. предполагается возможное ускорение.

Arjevani Y. and Shamir O. Communication complexity of distributed convex learning and optimization



# Оптимальный алгоритм

- У данной проблемы довольно большая история:

Reference	Communication complexity	Local gradient complexity	Order	Limitations
DANE [42]	$\mathcal{O}\left(\frac{\delta^2}{\mu^2} \log \frac{1}{\epsilon}\right)$	— <sup>(2)</sup>	1st	quadratic
DiSCO [51]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} (\log \frac{1}{\epsilon} + C^2 \Delta F_0) \log \frac{L}{\mu}\right)$	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} (\log \frac{1}{\epsilon} + C^2 \Delta F_0) \log \frac{L}{\mu}\right)$	2nd	$C$ - self-concordant <sup>(3)</sup>
AIDE [40]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon} \log \frac{L}{\delta}\right)$	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \sqrt{\frac{L}{\mu}} \log \frac{1}{\epsilon} \log \frac{L}{\delta}\right)$ <sup>(4)</sup>	1st	quadratic
DANE-LS [50]	$\mathcal{O}\left(\frac{\delta}{\mu} \log \frac{1}{\epsilon}\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \frac{\delta^{3/2}}{\mu^{3/2}} \log \frac{1}{\epsilon}\right)$ <sup>(5)</sup>	1st/2nd	quadratic <sup>(6)</sup>
DANE-HB [50]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon}\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \frac{\delta}{\mu} \log \frac{1}{\epsilon}\right)$ <sup>(5)</sup>	1st/2nd	quadratic <sup>(6)</sup>
SONATA [45]	$\mathcal{O}\left(\frac{\delta}{\mu} \log \frac{1}{\epsilon}\right)$	— <sup>(2)</sup>	1st	decentralized
SPAG [21]	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{1}{\epsilon}\right)$ <sup>(1)</sup>	— <sup>(2)</sup>	1st	$M$ - Lipschitz hessian
DiRegINA [12]	$\mathcal{O}\left(\frac{\delta}{\mu} \log \frac{1}{\epsilon} + \sqrt{\frac{M \delta R_0}{\mu}}\right)$	— <sup>(2)</sup>	2nd	$M$ - Lipschitz hessian
ACN [1]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon} + \sqrt{\frac{M \delta R_0}{\mu}}\right)$	— <sup>(2)</sup>	2nd	$M$ - Lipschitz hessian
Acc SONATA [46]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon} \log \frac{\delta}{\mu}\right)$	— <sup>(2)</sup>	1st	decentralized
This paper	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon}\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{1}{\epsilon}\right)$	1st	

В частности, подход зеркального спуска с необычной дивергенцией называется DANE.

# Оптимальный алгоритм

- У данной проблемы довольно большая история:

Reference	Communication complexity	Local gradient complexity	Order	Limitations
DANE [42]	$\mathcal{O}\left(\frac{\delta^2}{\mu^2} \log \frac{1}{\epsilon}\right)$	— <sup>(2)</sup>	1st	quadratic
DiSCO [51]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} (\log \frac{1}{\epsilon} + C^2 \Delta F_0) \log \frac{L}{\mu}\right)$	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} (\log \frac{1}{\epsilon} + C^2 \Delta F_0) \log \frac{L}{\mu}\right)$	2nd	$C$ - self-concordant <sup>(3)</sup>
AIDE [40]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon} \log \frac{L}{\delta}\right)$	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \sqrt{\frac{L}{\mu}} \log \frac{1}{\epsilon} \log \frac{L}{\delta}\right)$ <sup>(4)</sup>	1st	quadratic
DANE-LS [50]	$\mathcal{O}\left(\frac{\delta}{\mu} \log \frac{1}{\epsilon}\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \frac{\delta^{3/2}}{\mu^{3/2}} \log \frac{1}{\epsilon}\right)$ <sup>(5)</sup>	1st/2nd	quadratic <sup>(6)</sup>
DANE-HB [50]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon}\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \frac{\delta}{\mu} \log \frac{1}{\epsilon}\right)$ <sup>(5)</sup>	1st/2nd	quadratic <sup>(6)</sup>
SONATA [45]	$\mathcal{O}\left(\frac{\delta}{\mu} \log \frac{1}{\epsilon}\right)$	— <sup>(2)</sup>	1st	decentralized
SPAG [21]	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{1}{\epsilon}\right)$ <sup>(1)</sup>	— <sup>(2)</sup>	1st	$M$ - Lipschitz hessian
DiRegINA [12]	$\mathcal{O}\left(\frac{\delta}{\mu} \log \frac{1}{\epsilon} + \sqrt{\frac{M \delta R_0}{\mu}}\right)$	— <sup>(2)</sup>	2nd	$M$ - Lipschitz hessian
ACN [1]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon} + \sqrt{\frac{M \delta R_0}{\mu}}\right)$	— <sup>(2)</sup>	2nd	$M$ - Lipschitz hessian
Acc SONATA [46]	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon} \log \frac{\delta}{\mu}\right)$	— <sup>(2)</sup>	1st	decentralized
This paper	$\mathcal{O}\left(\sqrt{\frac{\delta}{\mu}} \log \frac{1}{\epsilon}\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{1}{\epsilon}\right)$	1st	

В частности, подход зеркального спуска с необычной дивергенцией называется DANE.

- Оптимальный алгоритм был предложен в 2022 году:



Kovalev D. et al. Optimal Gradient Sliding and its Application to Distributed Optimization Under Similarity

# Оптимальный алгоритм

Для задачи:

$$f(w) = g_1(w) + g_2(w),$$

где  $g_1 = f - f_1$  и  $g_2 = f_1$ .

---

## Algorithm Accelerated Extragradient

---

- 1: **Input:**  $w^0 = w_f^0 \in \mathbb{R}^d$
  - 2: **Parameters:**  $\tau \in (0, 1]$ ,  $\eta, \theta, \alpha > 0$ ,  $K \in \{1, 2, \dots\}$
  - 3: **for**  $k = 0, 1, 2, \dots, K - 1$  **do**
  - 4:      $w_g^k = \tau w^k + (1 - \tau) w_f^k$
  - 5:      $w_f^{k+1} \approx \underset{x \in \mathbb{R}^d}{\operatorname{argmin}} [\langle \nabla g_1(w_g^k), w - w_g^k \rangle + \frac{1}{2\theta} \|w - w_g^k\|^2 + g_2(w)]$
  - 6:      $w^{k+1} = w^k + \eta \alpha (w_f^{k+1} - w^k) - \eta \nabla g(w_f^{k+1})$
  - 7: **end for**
  - 8: **Output:**  $w^K$
-

# Три идеи

- 1 идея – Ускорение Нестерова
- 2 идея – Слайдинг
- 3 идея – Экстраградиент
- Первые две идеи понятны, ключевой является третья идея.

# Оптимально. Но может еще?

- **Вопрос:** забудем на 1 слайд про распределенку, и вспомним всегда ли метод Нестерова оптимальен?

# Оптимально. Но может еще?

- **Вопрос:** забудем на 1 слайд про распределенку, и вспомним всегда ли метод Нестерова оптимальен? Нет, если учитывать специфику, что целевая функция может иметь виды суммы  $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ .
- **Вопрос:** какой тогда метод является оптимальным? какие у него верхние оценки сходимости?

# Оптимально. Но может еще?

- **Вопрос:** забудем на 1 слайд про распределенку, и вспомним всегда ли метод Нестерова оптимальен? Нет, если учитывать специфику, что целевая функция может иметь виды суммы  $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ .
- **Вопрос:** какой тогда метод является оптимальным? какие у него верхние оценки сходимости?
- Метод называется Katyusha, он имеет следующую верхнюю оценку сходимости (оракульная сложность по вызову  $f_i$ ):

$$\mathcal{O}\left(\left[n + \sqrt{n\frac{L}{\mu}}\right] \log \frac{1}{\varepsilon}\right).$$



Allen-Zhu Z. Katyusha: the first direct acceleration of stochastic gradient methods

**Вопрос:** А какая верхняя оценка на оракульную сложность для метода Нестерова?

# Оптимально. Но может еще?

- **Вопрос:** забудем на 1 слайд про распределенку, и вспомним всегда ли метод Нестерова оптимальен? Нет, если учитывать специфику, что целевая функция может иметь виды суммы  $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ .
- **Вопрос:** какой тогда метод является оптимальным? какие у него верхние оценки сходимости?
- Метод называется Katyusha, он имеет следующую верхнюю оценку сходимости (оракульная сложность по вызову  $f_i$ ):

$$\mathcal{O}\left(\left[n + \sqrt{n\frac{L}{\mu}}\right] \log \frac{1}{\varepsilon}\right).$$



Allen-Zhu Z. Katyusha: the first direct acceleration of stochastic gradient methods

**Вопрос:** А какая верхняя оценка на оракульную сложность для метода Нестерова?  $\mathcal{O}\left(n\sqrt{\frac{L}{\mu}} \log \frac{1}{\varepsilon}\right)$

# Редукция дисперсии для similarity

- Идея метода редукции дисперсии:

$$\begin{aligned} \nabla f(x) \\ \downarrow \\ \nabla f_i(x) - \nabla f_i(w) + \nabla f(w), \end{aligned}$$

где  $i$  - генерируется случайно на каждой итерации из  $[n]$ ,  $w$  – референсная точка, которая обновляется редко (случайно или детерминистически).

- Идея метода редукции дисперсии для data similarity:

$$\begin{aligned} \nabla f(x) - \nabla f_1(x) \\ \downarrow \\ \nabla f_i(x) - \nabla f_i(w) + \nabla f(w) - f_1(x), \end{aligned}$$

где  $i$  - генерируется случайно на каждой итерации из  $[M]$ .

# Редукция дисперсии для similarity



Beznosikov A. & Gasnikov A. Compression and data similarity:  
Combination of two techniques for communication-efficient  
solving of distributed variational inequalities



Beznosikov A. & Gasnikov A. Similarity, Compression and Lo-  
cal Steps: Three Pillars of Efficient Communications for Dis-  
tributed Variational Inequalities



Khaled A. & Jin C. Faster federated optimization under  
second-order similarity

- Старая оценка:

$$\mathcal{O}\left(M\sqrt{1 + \frac{\delta}{\mu} \log \frac{1}{\varepsilon}}\right).$$

- Что можно "выбить":

$$\mathcal{O}\left(\left[M + \frac{\delta^2}{\mu^2}\right] \log \frac{1}{\varepsilon}\right) \quad \text{or} \quad \mathcal{O}\left(\left[M + \sqrt{M}\frac{\delta}{\mu}\right] \log \frac{1}{\varepsilon}\right) \quad \text{or}$$

$$\mathcal{O}\left(\left[M + M^{3/4} \sqrt{\frac{\delta}{\mu}}\right] \log \frac{1}{\varepsilon}\right).$$